

# Kompresa dat

Jan Outrata



KATEDRA INFORMATIKY  
UNIVERZITA PALACKÉHO V OLOMOUCI

přednášky

- Sayood K.: *Introduction to Data Compression*, Fourth Edition. Morgan Kaufmann, 2012. ISBN 978-0124157965
- Salomon D., Motta G.: *Handbook of Data Compression*, 5th edition. Springer, 2010. ISBN 978-1848829022
- Salomon D.: *Data Compression: The complete Reference*, 4th edition. Springer, 2006. ISBN 978-1846286025
- Hankerson D. C., Harris G. A., Johnson P. D.: *Introduction to Information Theory and Data Compression*, Second Edition (Applied Mathematics). Chapman and Hall/CRC, 2003. ISBN 978-1584883135
- Sayood K.: *Lossless compression handbook*. Academic Press, 2003. ISBN 0126208611

# Úvod

= zmenšení velikosti reprezentace obsahu/dat – jeden z účelů kódování dat,  
(experimentální) vědní obor

## Dvě fáze:

- 1 identifikování a modelování struktury dat s vynecháním redundancí
  - struktura např. opakování vzorů, statistická  $\approx$  frekvence/četnost vzorů, korelace mezi vzory, vzory elementární symboly nebo skupiny symbolů, také např. daná zdrojem dat  $\rightarrow$  modelování zdroje a syntéza dat (zvuk)
  - také různé modely pro různé části dat
- 2 kódování dat podle modelu
  - plus případně kódování (části) modelu
  - také predikce hodnoty dle modelu a kódování rozdílu (residua)
  - typicky binární kód

## Příklad

$$x_1, x_2, \dots, x_{12} = 2, 2, 4, 6, 7, 7, 7, 10, 10, 11, 11, 14$$

## Příklad

$x_1, x_2, \dots, x_{12} = 2, 2, 4, 6, 7, 7, 7, 10, 10, 11, 11, 14$

**1** číslo ve dvojkové soustavě  $\Rightarrow$  4 b/číslo = 48 b

## Příklad

$x_1, x_2, \dots, x_{12} = 2, 2, 4, 6, 7, 7, 7, 10, 10, 11, 11, 14$

**1** číslo ve dvojkové soustavě  $\Rightarrow 4 \text{ b/číslo} = 48 \text{ b}$

**2** 7 různých čísel ve dvojkové soustavě  $\Rightarrow 3 \text{ b/číslo} = 36 \text{ b}$

## Příklad

$x_1, x_2, \dots, x_{12} = 2, 2, 4, 6, 7, 7, 7, 10, 10, 11, 11, 14$

**1** číslo ve dvojkové soustavě  $\Rightarrow 4 \text{ b/číslo} = 48 \text{ b}$

**2** 7 různých čísel ve dvojkové soustavě  $\Rightarrow 3 \text{ b/číslo} = 36 \text{ b}$

**3** častější číslo kratší kód  $\rightarrow 2 \times 2, 1 \times 4, 1 \times 6, 3 \times 7, 2 \times 10, 2 \times 11, 1 \times 14 \rightarrow \mathbf{0I}$  pro 7, **III** pro 11, **II0** pro 10, **I0I** pro 2, **I00** pro 14, **000** pro 4 a **00I** pro 6  $\Rightarrow 33 \text{ b} = 2.75 \text{ b/číslo}$



## Příklad

$x_1, x_2, \dots, x_{12} = 2, 2, 4, 6, 7, 7, 7, 10, 10, 11, 11, 14$

- 1 číslo ve dvojkové soustavě  $\Rightarrow 4 \text{ b/číslo} = 48 \text{ b}$
- 2 7 různých čísel ve dvojkové soustavě  $\Rightarrow 3 \text{ b/číslo} = 36 \text{ b}$
- 3 častější číslo kratší kód  $\rightarrow 2 \times 2, 1 \times 4, 1 \times 6, 3 \times 7, 2 \times 10, 2 \times 11, 1 \times 14 \rightarrow \mathbf{0I}$  pro 7,  $\mathbf{III}$  pro 11,  $\mathbf{II0}$  pro 10,  $\mathbf{IOI}$  pro 2,  $\mathbf{I00}$  pro 14,  $\mathbf{000}$  pro 4 a  $\mathbf{00I}$  pro 6  $\Rightarrow 33 \text{ b} = 2.75 \text{ b/číslo}$
- 4 kódování opakování čísla  $\rightarrow \mathbf{0}$  pro žádné,  $\mathbf{I0}$  pro jedno a  $\mathbf{II}$  pro dvě  $\Rightarrow 7 \times 3 + 11 = 32 \text{ b} = 2.\bar{6} \text{ b/číslo}$

## Příklad

$x_1, x_2, \dots, x_{12} = 2, 2, 4, 6, 7, 7, 7, 10, 10, 11, 11, 14$

- 1 číslo ve dvojkové soustavě  $\Rightarrow 4 \text{ b/číslo} = 48 \text{ b}$
- 2 7 různých čísel ve dvojkové soustavě  $\Rightarrow 3 \text{ b/číslo} = 36 \text{ b}$
- 3 častější číslo kratší kód  $\rightarrow 2 \times 2, 1 \times 4, 1 \times 6, 3 \times 7, 2 \times 10, 2 \times 11, 1 \times 14 \rightarrow \mathbf{0I}$  pro 7,  $\mathbf{III}$  pro 11,  $\mathbf{II0}$  pro 10,  $\mathbf{IOI}$  pro 2,  $\mathbf{I00}$  pro 14,  $\mathbf{000}$  pro 4 a  $\mathbf{00I}$  pro 6  $\Rightarrow 33 \text{ b} = 2.75 \text{ b/číslo}$
- 4 kódování opakování čísla  $\rightarrow \mathbf{0}$  pro žádné,  $\mathbf{I0}$  pro jedno a  $\mathbf{II}$  pro dvě  $\Rightarrow 7 \times 3 + 11 = 32 \text{ b} = 2.\bar{6} \text{ b/číslo}$
- 5 malé rozdíly mezi sousedními čísly  $\rightsquigarrow$  predikce  $\rightarrow d_1 = x_1 = 2$ ,  
 $d_i = x_i - x_{i-1} = 0, 2, 2, 1, 0, 0, 3, 0, 1, 0, 3 \rightarrow 4 \text{ b} + 2 \text{ b/číslo} \Rightarrow 26 \text{ b} = 2.1\bar{6} \text{ b/číslo}$

## Příklad

$x_1, x_2, \dots, x_{12} = 2, 2, 4, 6, 7, 7, 7, 10, 10, 11, 11, 14$

- 1** číslo ve dvojkové soustavě  $\Rightarrow 4 \text{ b/číslo} = 48 \text{ b}$
- 2** 7 různých čísel ve dvojkové soustavě  $\Rightarrow 3 \text{ b/číslo} = 36 \text{ b}$
- 3** častější číslo kratší kód  $\rightarrow 2 \times 2, 1 \times 4, 1 \times 6, 3 \times 7, 2 \times 10, 2 \times 11, 1 \times 14 \rightarrow \mathbf{0I}$  pro 7, **III** pro 11, **II0** pro 10, **I0I** pro 2, **I00** pro 14, **000** pro 4 a **00I** pro 6  $\Rightarrow 33 \text{ b} = 2.75 \text{ b/číslo}$
- 4** kódování opakování čísla  $\rightarrow \mathbf{0}$  pro žádné, **I0** pro jedno a **II** pro dvě  $\Rightarrow 7 \times 3 + 11 = 32 \text{ b} = 2.\bar{6} \text{ b/číslo}$
- 5** malé rozdíly mezi sousedními čísly  $\rightsquigarrow$  predikce  $\rightarrow d_1 = x_1 = 2,$   
 $d_i = x_i - x_{i-1} = 0, 2, 2, 1, 0, 0, 3, 0, 1, 0, 3 \rightarrow 4 \text{ b} + 2 \text{ b/číslo} \Rightarrow 26 \text{ b} = 2.1\bar{6} \text{ b/číslo}$
- 6** vztah mezi čísly  $\rightsquigarrow$  predikce  $\rightarrow \hat{x}_i = i + 1 \rightarrow$   
 $d_i = x_i - \hat{x}_i = 0, -1, 0, 1, 1, 0, -1, 1, 0, 0, -1, 1 \rightarrow \mathbf{0}$  pro 0, **I0** pro -1 a **II** pro 1  $\Rightarrow 19 \text{ b} = 1.58\bar{3} \text{ b/číslo}$

- využití („zneužití“) omezení reprodukční techniky a příjemce obsahu (člověka) pro vynechání nevyužitelných informací (obraz, video, zvuk)
  - data . . . znaky textu, vzorky obrazu (body) a videa (body v čase), zvuku (úrovně v čase), aj., digitální (digitalizovaná) forma, narůstající objem – např. obraz foto 10 Mpx 24 bpp  $\sim$  30 MB, video HDTV 1920  $\times$  1080 12 bpp, 25 fps  $\sim$  590 Mb/s, zvuk CD 44.1 kHz, 16 bps, stereo  $\sim$  1.3 Mb/s
  - vývoj úložných a přenosových technologií nestačí, navíc (fyzikální) omezení
  - umožnění tzv. multimediální revoluce – komprese textu, obrazu, videa, zvuku při uložení a přenosu
- všudypřítomná – počítače, spotřební elektronika, komunikační a distribuční sítě, . . .

## Příklady z minulosti

- morseovka: písmena (a číslice a interpunkce) kódována do posloupností teček a čárek, častější (e, t) kratšími pro zmenšení průměrné délky textu
- Braillovo písmo: do 2  $\times$  3 matice teček kódována písmena (a číslice, interpunkce aj., Grade 1) a častá slova (a jejich zkratky, Grade 2)



A 1	B 2	C 3	D 4	E 5
F 6	G 7	H 8	I 9	J 0
K	L	M	N	O
P	Q	R	S	T
U	V	W	X	Y
Z	číslo	Malé písmeno	Velké písmeno	

- = dva algoritmy: kompresní pro kompresi originálních dat na komprimovaná a dekompresní (rekonstrukční) pro dekompresi komprimovaných dat na dekomprimovaná (rekonstruovaná)
- standardy: ISO, ITU-T aj.

## Bezeztrátové (lossless)

- = dekomprimovaná data stejná jako data originální = žádná ztráta informace v datech
- např. pro text, programové (binární) soubory, citlivé záznamy (bankovní, zdravotní), nereprodukovatelná data (snímky v čase) aj.
- statistické: Huffmanovo a aritmetické kódování
- kontextové: PPM
- slovníkové: LZ\*
- jiné: BWT, ACB, obrazové (JPEG-LS, JBIG)

## Ztrátové(lossy)

- = při kompresi vynechání nějaké informace v originálních datech → dekomprimovaná data (obecně) odlišná od originálních dat = ztráta informace z originálních dat – zkreslení dat
- vyšší míra komprese než u bezztrátových za cenu vyšší míry zkreslení dat
- např. pro obraz, video, zvuk (hudba, řeč) – zkreslení dat vede k artefaktům při reprodukci obsahu
- vzorkování a kvantizace: skalární a vektorová
- diferenční kódování: DPCM, delta modulace
- transformační a podpásmové kódování: Fourierova, Z a kosinová transformace, wavelety
- aplikace: obraz – JPEG, fraktály, video – H.\*, MPEG, zvuk – MDCT, G.\*, MPEG, LPC, CELP

- asymptotická časová a paměťová složitost algoritmů komprese a dekomprese
- experimentální časová a paměťová náročnost algoritmů – jejich implementací na referenčních datech
- míry komprese
  - kompresní poměr (compression ratio) = poměr velikosti originálních a komprimovaných dat, také jako procento velikosti komprimovaných dat z velikosti originálních dat
  - compression rate = průměrná velikost komprimovaných dat na vzorek originálních dat, např. pixel u obrazu – bitů/pixel, sekunda u videa a zvuku – bitů/s
  - na referenčních datech
- míry zkreslení (distortion) – rozdíl mezi originálními a dekomprimovanými daty, více způsobů měření „přesnosti (fidelity)“ a „kvality“ obsahu, viz dále, na referenčních datech



## Fyzický

- = popis zdroje dat – např. měřených, popis měřidla
  - u ztrátové komprese zvuku (řeči) – popis syntezátoru a syntéza dat
  - obecně příliš složitý nebo nemožný

## Pravděpodobnostní model

- = empiricky zjištěný statistický popis zdroje dat
  - pro statistické a kontextové bezztrátové kompresní metody
  - ignorantní: výskyt každé hodnoty na výstupu zdroje dat je nezávislý na výskytu ostatních hodnot a je se stejnou pravděpodobností – nejjednodušší
  - dostupná pravděpodobnost výskytu nezávisle se vyskytujícími hodnotami
  - pravděpodobnost:
    - frekvence/četnost výskytu výsledku experimentu (hodnot na výstupu zdroje dat) –  $n$  opakování experimentu,  $n_i$  výskytů výsledku  $\omega_i \in \Omega, i \in \{1, 2, \dots, N\}$  ( $\Omega \dots$  prostor výsledků (sample space))  $\rightarrow$  frekvence/četnost výskytu výsledku  $\omega_i$ :  $f(\omega_i) = f_i = \frac{n_i}{n} =$  přibližná hodnota/odhad pro pravděpodobnost výskytu výsledku  $\omega_i$ :  
 $P(\omega_i) = p_i = \lim_{n \rightarrow \infty} \frac{n_i}{n}$ , událost (event)  $A \subseteq \Omega$ , výskyt události = výskyt kteréhokoliv výsledku události,  $f(A) \geq 0 \Rightarrow P(A) \geq 0$  (1),  $P(\Omega) = 1$  (2),  $B \subseteq \Omega, A \cap B = \emptyset \Rightarrow P(A \cup B) = P(A) + P(B)$  (3),  $\sum_i P(\omega_i) = 1$

## Pravděpodobnostní model

### ■ pravděpodobnost:

- míra víry (belief) v událost – a priori pravděpodobnost  $P(A)$  události  $A$  před výskytem události (získání informace)  $B$ , a posteriori pravděpodobnost  $P(A|B)$  po/za předpokladu, sdružená (joint) pravděpodobnost  $P(A, B)$  výskytu obou událostí  $A, B$ , Bayesovo pravidlo  $P(A|B) = \frac{P(A, B)}{P(B)}$ , (statisticky) nezávislé události  $\dots P(A, B) = P(A)P(B)$ , tj. při  $P(A|B) = P(A)$ , pro případy, kdy experiment není možné provést
- míra („velikost“) události (jako množiny) – jako jiné míry (1) a (3), normalizace (2) = axiomy, z nich např.  $P(\bar{A}) = 1 - P(A)$ ,  $P(\emptyset) = 0$ ,  $P(A \cup B) = P(A) + P(B) - P(A \cap B)$  aj., pro nediskrétní prostor výsledků

## Pravděpodobnostní model

- náhodná proměnná/veličina: měřitelné  $X : \Omega \mapsto \mathbb{R}$  ( $\mathbb{R}$  ... obor reálných čísel), realizace  $X(\omega) = x$ , např.  $P(X(\omega) \leq x) = P(X \leq x)$ , diskrétní a spojitá
- rozdělení pravděpodobnosti: distribuční funkce/kumulovaná pravděpodobnost (cumulative distribution function)  $F_X(x) = P(X \leq x)$ ,  $x_1 \geq x_2 \Rightarrow F_X(x_1) \geq F_X(x_2)$ ,  $P(X = x) = F_X(x) - F_X(x^-)$  pro  $F_X(x^-) = P(X < x)$ , rozdělení/distribuce/hustota pravděpodobnosti (probability distribution/density function)  $f_X(x)$  ... difference/derivace  $F_X(x)$  pro diskrétní/spojitou  $X$ , pro diskrétní typicky  $f_X(x) = P(X = x)$ , např. binomické, Poissonovo, uniformní, normální (Gaussovo), aj.
- sdružená (joint) distribuční funkce  $F_{X_1 X_2 \dots X_n}(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$ , sdružené rozložení pravděpodobnosti  $f_{X_1 X_2 \dots X_n}(x_1, x_2, \dots, x_n)$ , marginální pro jednotlivé  $X_i$ ,  $X_1, X_2$  nezávislé, jestliže  $F_{X_1 X_2}(x_1, x_2) = F_{X_1}(x_1)F_{X_2}(x_2)$  (a tedy i  $f_{X_1 X_2}(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2)$ )

## Pravděpodobnostní model

- střední hodnota (expected value) náhodné proměnné  $X$ :  $E[X] = \sum_i x_i P(X = x_i)$  pro diskrétní  $X$ ,  $E[X] = \int_{-\infty}^{\infty} x f_X(x) dx$  pro spojitou  $X$ , statistický průměr (mean, statistical average)  $\mu_X = E[X]$ , rozptyl (variance)  $\sigma_X^2 = E[(X - \mu_X)^2] = E[X^2] - \mu_X^2$ , standardní odchylka (standard deviation)  $\sigma_X = \sqrt{\sigma_X^2}$ ,  $X_1, X_2$  nekorelované, jestliže  $E[(X_1 - \mu_1)(X_2 - \mu_2)] = 0$
- náhodný/stochastický proces: měřitelné  $X : \Omega \mapsto \mathcal{F}$ ,  $\mathcal{F} : \mathbb{R} \mapsto \mathbb{R}$ , realizace  $X(\omega) = x(t)$ ,  $-\infty < t < \infty$  funkce času, ensemble  $X(t) = \{x_\omega(t)\}$ , střední hodnota ensemble, vzorek (sample)  $X(t_0)$  ensemble = náhodná proměnná
- problém nulové pravděpodobnosti/frekvence (zero probability/frequency problem): kompresní metody předpokládají u modelu všechny uvažované pravděpodobnosti/frekvence nenulové  $\rightarrow$  místo nulových nastavení velice malých

## Markovův model (Andrei A. Markov)

- výskyt hodnoty  $x_j$  na výstupu zdroje dat je závislý na výskytu (některých, ne nutně bezprostředně) předchozích hodnot  $x_i, i < j$
- vychází z pravděpodobnostního modelu
- v bezztrátové kompresi Markovův řetěz s diskrétním časem: posloupnost hodnot  $x_j$  (náhodné proměnné  $X_j$ ) následuje Markovův model/proces  $k$ -tého řádu, jestliže  $P(x_j|x_{i_1}, x_{i_2}, \dots, x_{i_k}) = P(x_j|x_{j-1}, x_{j-2}, \dots), i_1, i_2, \dots, i_k < j$  (znalost některých předchozích  $k$  hodnot je stejná jako znalost všech předchozích hodnot), posloupnosti  $s_j$  hodnot  $x_{i_1}, x_{i_2}, \dots, x_{i_k}$  = stavy modelu/procesu/řetězu,  $P(x_j|s_j)$  = pravděpodobnosti přechodu mezi stavy
- nejběžnější model 1. řádu:  $P(x_j|x_i) = P(x_j|x_{j-1}, x_{j-2}, \dots), i < j$
- $s_j, P(s_j), P(x_j|s_j)$  ... stavový diagram
- různé modely podle formy závislosti, se zvyšujícím se  $k$  vyšší míra komprese než s nezávislými výskyty hodnot
- v kompresi textu Markovův model  $k$ -tého řádu = model konečného kontextu (finite context model) – kontext = stav modelu

## Markovův model

### Příklad

$$x_1 x_2 \dots x_{10} = aababbabaa$$

stavy modelu 1. řádu = posloupnosti (bezprostředně) předchozích symbolů délky 1 pro všechny symboly:  $a, b$

$$P(a) = \frac{6}{10}, P(b) = \frac{4}{10},$$

$$P(a|a) = \frac{2}{5}, P(b|a) = \frac{3}{5}, P(a|b) = \frac{3}{4}, P(b|b) = \frac{1}{4}$$

stavy modelu 2. řádu = posloupnosti (bezprostředně) předchozích symbolů délky 2 pro všechny symboly:  $aa, ab, ba, bb$

$$P(aa) = \frac{2}{9}, P(ab) = \frac{3}{9}, P(ba) = \frac{3}{9}, P(bb) = \frac{1}{9},$$

$$P(a|aa) \rightarrow 0, P(b|aa) \rightarrow 1, P(a|ab) = \frac{2}{3}, P(b|ab) = \frac{1}{3}, P(a|ba) = \frac{1}{3}, P(b|ba) = \frac{2}{3},$$

$$P(a|bb) \rightarrow 1, P(b|bb) \rightarrow 0$$

## Typy

- statický – neměnný pro různá originální data a během kódování, známý algoritmu dekomprese
- semi-adaptivní – vytvořený pro originální data (1. průchod daty při kompresi), během kódování neměnný (2. průchod) a předaný algoritmu dekomprese (např. s komprimovanými daty)
- adaptivní – dynamicky vytvářený/modifikovaný podle doposud zakódovaných originálních a dekomprimovaných dat

## Klasická Shannonova

- rámec pro bezztrátové kompresní metody, vychází z pravděpodobnostního modelu dat
- Claude E. Shannon: A Mathematical Theory of Communication. *Bell System Technical Journal* **27**, pp. 379–423, 623–656, 1948.
- „míra průměrné informace (asociované s) experimentu(-em)“ – požadavky, pro nezávislé jevy  $A_i, i = 1, \dots, m, \bigcup A_i = \Omega$ :
  - 1 spojitá funkce  $H(p_i), p_i = P(A_i)$
  - 2 monotónně rostoucí vzhledem k počtu  $m$  stejně pravděpodobných jevů  $A_i$  ( $p_i = \frac{1}{m}$ )
  - 3 stejná při rozdělení experimentu na  $k$  podexperimentů (s disjunktními podmnožinami množiny jevů  $A_i$ ), výsledek experimentu = podmnožina s jevem, výsledek podexperimentu = jev v podmnožině:
 
$$H(p_i) = H(q_1, q_2, \dots, q_k) + q_1 H\left(\frac{p_1}{q_1}, \frac{p_2}{q_1}, \dots, \frac{p_{j_1}}{q_1}\right) + q_2 H\left(\frac{p_{j_1+1}}{q_2}, \frac{p_{j_1+2}}{q_2}, \dots, \frac{p_{j_2}}{q_2}\right) + \dots + q_k H\left(\frac{p_{j_{k-1}+1}}{q_k}, \frac{p_{j_{k-1}+2}}{q_k}, \dots, \frac{p_{j_k}}{q_k}\right),$$

$$q_1 = \sum_{i=1}^{j_1} p_i, q_2 = \sum_{i=j_1+1}^{j_2} p_i, \dots, q_k = \sum_{i=j_{k-1}+1}^{j_k} p_i$$
- jediné možné řešení požadavků (Shannon):  $H(p_i) = -K \sum_i p_i \log p_i$ ,  $K$  kladná konstanta



## Klasická Shannonova

- informace (self-information) (asociovaná s výskytem) jevu  $A$ :  
$$i(A) = \log_b \frac{1}{P(A)} = -\log_b P(A) \quad - \quad \log(1) = 0 \text{ a roste s klesající } P(A) \neq 0, \text{ pro}$$
  
nezávislé  $A, B$   $i(AB) = i(A) + i(B)$
- jednotka  $i$ : bit (shannon) pro  $b = 2$ , nat pro  $b = e$ , hartley pro  $b = 10$
- entropie (asociovaná s) experimentu(-em): průměr  
$$H(A_i) = \sum_i P(A_i) i(A_i) = -\sum_i P(A_i) \log P(A_i)$$
 informací nezávislých jevů  
 $A_i, \cup A_i = \Omega$  (jako náhodných proměnných),  $0 \log 0 := 0$
- Shannon: experiment = zdroj  $Z$  posloupnosti  $X_1, X_2, \dots, X_n$  symbolů z množiny  $\{a_1, a_2, \dots, a_m\}$  jako náhodných proměnných  $X_j(a_i) = i$ , pak entropie zdroje = průměrný počet binárních symbolů (bitů) potřebných pro zakódování každého symbolu posloupnosti =  $H(Z) = \lim_{n \rightarrow \infty} \frac{1}{n} G_n$ ,  $G_n = -\sum_{i_1=1}^m \sum_{i_2=1}^m \dots \sum_{i_n=1}^m P(X_1 = i_1, X_2 = i_2, \dots, X_n = i_n) \log P(X_1 = i_1, X_2 = i_2, \dots, X_n = i_n)$  – limit pro bezeztrátovou kompresi

## Klasická Shannonova

- jestliže je výskyt každého symbolu  $X_j$  (jako náhodné proměnné) nezávislý a stejně pravděpodobnostně rozložený, pak  $X_j = X$ ,  $G_n = -n \sum_{i=1}^m P(X = i) \log P(X = i)$  a  $^1H(Z) = -\sum_{i=1}^m P(a_i) \log P(a_i) =$  entropie 1. řádu
- podmíněná entropie (pro náhodné proměnné)  $X_1$  v závislosti na  $X_2$ : průměr  $H(Z) = H(X_1|X_2) = \sum_{i_2=1}^m P(a_{i_2}) H(X_1|X_2 = i_2) = -\sum_{i_2=1}^m P(a_{i_2}) \sum_{i_1=1}^m P(a_{i_1}|a_{i_2}) \log P(a_{i_1}|a_{i_2})$  podmíněných entropií  $X_1$  v závislosti na  $X_2 = i_2$
- entropie Markovova modelu 1. řádu se stavy  $S = \{s_j\}$ :  $H(X|S)$
- entropie (obecně) nezjistitelná  $\Rightarrow$  odhad závislý na modelu struktury dat!

## Klasická Shannonova

### Příklad

$x_1, x_2, \dots, x_{12} = 2, 2, 4, 6, 7, 7, 7, 10, 10, 11, 11, 14$

■  $\{a_1, a_2, \dots, a_7\} = \{2, 4, 6, 7, 10, 11, 14\}$

$$P(a_i) = p_i \approx f(a_i) = f_i: f_1 = f_5 = f_6 = \frac{2}{12}, f_2 = f_3 = f_7 = \frac{1}{12}, f_4 = \frac{3}{12}$$

$$^1H(a_i) = -\sum_{i=1}^7 p_i \log_2 p_i \doteq 2.689 \text{ bitů/číslo}$$

## Klasická Shannonova

### Příklad

$x_1, x_2, \dots, x_{12} = 2, 2, 4, 6, 7, 7, 7, 10, 10, 11, 11, 14$

- $\{a_1, a_2, \dots, a_7\} = \{2, 4, 6, 7, 10, 11, 14\}$

$$P(a_i) = p_i \approx f(a_i) = f_i: f_1 = f_5 = f_6 = \frac{2}{12}, f_2 = f_3 = f_7 = \frac{1}{12}, f_4 = \frac{3}{12}$$

$$^1H(a_i) = -\sum_{i=1}^7 p_i \log_2 p_i \doteq 2.689 \text{ bitů/číslo}$$

- Sousední čísla nejsou nezávislá  $\rightarrow$  odstranění závislosti (korelace):

$$d_2, d_3, \dots, d_{12} = 0, 2, 2, 1, 0, 0, 3, 0, 1, 0, 3, \{a_1, a_2, a_3, a_4\} = \{0, 1, 2, 3\}$$

$$f_1 = \frac{5}{11}, f_2 = f_3 = f_4 = \frac{2}{11}$$

$$^1H(a_i) = -\sum_{i=1}^4 p_i \log_2 p_i \doteq 1.859 \text{ bitů/číslo}$$

## Klasická Shannonova

### Příklad

$x_1, x_2, \dots, x_{12} = 2, 2, 4, 6, 7, 7, 7, 10, 10, 11, 11, 14$

- $\{a_1, a_2, \dots, a_7\} = \{2, 4, 6, 7, 10, 11, 14\}$

$$P(a_i) = p_i \approx f(a_i) = f_i: f_1 = f_5 = f_6 = \frac{2}{12}, f_2 = f_3 = f_7 = \frac{1}{12}, f_4 = \frac{3}{12}$$

$$^1H(a_i) = -\sum_{i=1}^7 p_i \log_2 p_i \doteq 2.689 \text{ bitů/číslo}$$

- Sousední čísla nejsou nezávislá  $\rightarrow$  odstranění závislosti (korelace):

$$d_2, d_3, \dots, d_{12} = 0, 2, 2, 1, 0, 0, 3, 0, 1, 0, 3, \{a_1, a_2, a_3, a_4\} = \{0, 1, 2, 3\}$$

$$f_1 = \frac{5}{11}, f_2 = f_3 = f_4 = \frac{2}{11}$$

$$^1H(a_i) = -\sum_{i=1}^4 p_i \log_2 p_i \doteq 1.859 \text{ bitů/číslo}$$

- Všechna čísla jsou mezi sebou závislá  $\rightarrow$  odstranění závislosti (korelace):

$$d_1, d_2, \dots, d_{12} = 0, -1, 0, 1, 1, 0, -1, 1, 0, 0, -1, 1, \{a_1, a_2, a_3\} = \{0, -1, 1\}$$

$$f_1 = \frac{5}{12}, f_2 = \frac{3}{12}, f_3 = \frac{4}{12}$$

$$^1H(a_i) = -\sum_{i=1}^3 p_i \log_2 p_i \doteq 1.555 \text{ bitů/číslo}$$

## Klasická Shannonova

### Příklad

$$x_1 x_2 \dots x_{10} = aababbabaa$$

výskyt  $a$  a  $b$  nezávislý:  $P(a) = \frac{6}{10}$ ,  $P(b) = \frac{4}{10}$

$$H = -P(a) \log_2 P(a) - P(b) \log_2 P(b) \doteq 0.971 \text{ b/symbol}$$

## Klasická Shannonova

### Příklad

$$x_1 x_2 \dots x_{10} = aababbabaa$$

výskyt  $a$  a  $b$  nezávislý:  $P(a) = \frac{6}{10}$ ,  $P(b) = \frac{4}{10}$

$$H = -P(a) \log_2 P(a) - P(b) \log_2 P(b) \doteq 0.971 \text{ b/symbol}$$

Markovův model 1. řádu:  $P(a) = \frac{5}{9}$ ,  $P(b) = \frac{4}{9}$ ,

$$P(a|a) = \frac{2}{5}, P(b|a) = \frac{3}{5}, P(a|b) = \frac{3}{4}, P(b|b) = \frac{1}{4}$$

$$H = P(a)H(X|a) + P(b)H(X|b) = P(a)(-P(a|a) \log_2 P(a|a) - P(b|a) \log_2 P(b|a)) + P(b)(-P(a|b) \log_2 P(a|b) - P(b|b) \log_2 P(b|b)) \doteq 0.9 \text{ b/symbol}$$

## Klasická Shannonova

### Příklad

$$x_1 x_2 \dots x_{10} = aababbabaa$$

výskyt  $a$  a  $b$  nezávislý:  $P(a) = \frac{6}{10}$ ,  $P(b) = \frac{4}{10}$   
 $H = -P(a) \log_2 P(a) - P(b) \log_2 P(b) \doteq 0.971 \text{ b/symbol}$

Markovův model 1. řádu:  $P(a) = \frac{5}{9}$ ,  $P(b) = \frac{4}{9}$ ,  
 $P(a|a) = \frac{2}{5}$ ,  $P(b|a) = \frac{3}{5}$ ,  $P(a|b) = \frac{3}{4}$ ,  $P(b|b) = \frac{1}{4}$   
 $H = P(a)H(X|a) + P(b)H(X|b) = P(a)(-P(a|a) \log_2 P(a|a) - P(b|a) \log_2 P(b|a)) +$   
 $P(b)(-P(a|b) \log_2 P(a|b) - P(b|b) \log_2 P(b|b)) \doteq 0.9 \text{ b/symbol}$

Markovův model 2. řádu:  $P(aa) = \frac{1}{8}$ ,  $P(ab) = \frac{3}{8}$ ,  $P(ba) = \frac{3}{8}$ ,  $P(bb) = \frac{1}{8}$ ,  
 $P(a|aa) \rightarrow 0$ ,  $P(b|aa) \rightarrow 1$ ,  $P(a|ab) = \frac{2}{3}$ ,  $P(b|ab) = \frac{1}{3}$ ,  $P(a|ba) = \frac{1}{3}$ ,  $P(b|ba) = \frac{2}{3}$ ,  
 $P(a|bb) \rightarrow 1$ ,  $P(b|bb) \rightarrow 0$   
 $H = \sum_{x_1 x_2 = aa}^{bb} P(x_1 x_2) H(X|x_1 x_2) =$   
 $\sum_{x_1 x_2 = aa}^{bb} P(x_1 x_2) - \sum_{y=a,b} P(y|x_1 x_2) \log_2 P(y|x_1 x_2) \doteq 0.689 \text{ b/symbol}$



## Klasická Shannonova

Uvažováním závislosti mezi symboly dat (posloupnosti) v modelu struktury dat snižujeme „entropii dat“. Entropie je vlastnost (hypotetického) zdroje dat a je stejná pro všechna data ze zdroje. Snižujeme odhad této entropie uvažováním delších  $n$ -tic symbolů dat a závislostí mezi nimi v modelu (až do  $n \rightarrow \infty$ )!

## Algoritmická

- Kolmogorov/descriptive complexity / algoritmická entropie dat (Andrey N. Kolmogorov): délka nejmenšího/nejkratšího počítačového programu (včetně vstupu, v jakémkoliv programovacím jazyce), jehož jsou data výstupem – způsob modelování struktury dat
- není znám žádný systematický způsob výpočtu nebo libovolně blízkého odhadu
- Minimum Description Length (MDL) princip (J. Rissanen):  
 $MDL(x) = \min_j (D_{M_j} + R_{M_j}(x))$ ,  $D_{M_j}$  délka popisu možného modelu  $M_j$  struktury dat  $x$ ,  $R_{M_j}(x)$  délka reprezentace  $x$  podle modelu  $M_j$
- např.  $M_j$  polynomy  $j$ -tého řádu: pro vyšší  $j$  kratší  $R_{M_j}(x)$  (přesnější model), ale delší  $D_{M_j}$  (složitější model), a naopak  $\Rightarrow$  kompromis

- abeceda  $A = \{a_1, a_2, \dots, a_n\}$ ,  $a_i$  = symboly
- = (kód) ze zdrojové abecedy  $A$  do kódové abecedy  $B$ : injektivní  $C : A \mapsto B^+$ ,  $B^+ =$  množina konečných neprázdných posloupností (= slov) symbolů z  $B$  – často  $B = \{0, 1\} \rightarrow$  binární kódování (kód)
- $C(a_i) \in B^+$  ... kódové slovo (kód) pro symbol  $a_i$ ,  $C(A) = \{C(a_i), a_i \in A\} \subseteq B^+$  ... kód (pro zdrojovou abecedu  $A$ ),  $l(a_i)$  ... délka  $C(a_i)$ , pro  $B = \{0, 1\}$  v bitech
- dekódování:  $D : C(A) \mapsto A$
- např.  $\{0, 1, 00, 11\}$ , ne  $\{0, 0, 1, 11\}$
- blokový kód (kód pevné délky, fixed-length code) = všechna kódová slova (pro všechny symboly) mají stejnou délku, např. ASCII

## Jednoznačně dekódovatelný kód

- = každá (neprázdna) posloupnost symbolů z kódové abecedy je zřetězením nejvýše jedné posloupnosti kódových slov
- =  $C^+ : A^+ \mapsto B^+, C^+(a_{i_1}a_{i_2} \dots a_{i_j}) = C(a_{i_1})C(a_{i_2}) \dots C(a_{i_j})$  injektivní
  - dekódování:  $D^+ : C^+(A^+) \mapsto A^+$
  - např. každý blokový,  $\{0, 0I, 0II, III\}$ , ne  $\{0, 0I, IO, II\}$
  - test:  $S \leftarrow C(A)$  a opakuj  $S \leftarrow S \cup \{s \in B^+; ps \in S \wedge p \in S\}$  dokud některé  $s \in C(A)$  nebo  $S$  zůstane stejná, při  $s \in C(A)$  kód  $C(A)$  není jednoznačně dekódovatelný

## Prefixový (prefix, instantaneous) kód

- = žádné kódové slovo není prefixem jiného kódového slova
  - např. každý blokový,  $\{0, IO, IIO, III\}$
  - jednoznačně dekódovatelný

## Věta (Kraftova)

*Prefixový kód s  $k$  kódovými slovy délek  $l_1, l_2, \dots, l_k$  nad kódovou abecedou velikosti  $m$  existuje právě když*

$$\sum_{i=1}^k m^{-l_i} \leq 1 \quad \dots \quad \text{Kraftova nerovnost.}$$



## Věta (Kraftova)

*Prefixový kód s  $k$  kódovými slovy délek  $l_1, l_2, \dots, l_k$  nad kódovou abecedou velikosti  $m$  existuje právě když*

$$\sum_{i=1}^k m^{-l_i} \leq 1 \quad \dots \quad \text{Kraftova nerovnost.}$$



## Věta (McMillanova)

*Jednoznačně dekódovatelný kód s  $k$  kódovými slovy délek  $l_1, l_2, \dots, l_k$  nad kódovou abecedou velikosti  $m$  existuje právě když*

$$\sum_{i=1}^k m^{-l_i} \leq 1 \quad (\dots \quad \text{Kraft-McMillanova nerovnost}).$$



## Optimální kód

- pro pravděpodobnostní model dat (výskytu symbolů), prefixový kód
  - průměrná délka kódu (na symbol, code rate): průměr  $\bar{l}(C(A)) = \sum_{i=1}^n P(a_i)l(a_i)$  délek  $l(a_i)$  pro všechny  $a_i \in A$ ,  $P(a_i) \neq 0$  = pravděpodobnost výskytu symbolu  $a_i$
- = s minimální  $\bar{l}(C(A))$  (v rámci třídy kódů, např. prefixové)

## Optimální kód

- pro pravděpodobnostní model dat (výskytu symbolů), prefixový kód
- průměrná délka kódu (na symbol, code rate): průměr  $\bar{l}(C(A)) = \sum_{i=1}^n P(a_i)l(a_i)$  délek  $l(a_i)$  pro všechny  $a_i \in A$ ,  $P(a_i) \neq 0$  = pravděpodobnost výskytu symbolu  $a_i$   
= s minimální  $\bar{l}(C(A))$  (v rámci třídy kódů, např. prefixové)

### Věta (Shannon noiseless coding theorem)

*Pro optimální jednoznačně dekódovatelný kód ze zdrojové abecedy  $A$  do kódové abecedy  $B$  platí*

$$\frac{H(A)}{\log_b m} \leq \bar{l}(C(A)) < \frac{H(A)}{\log_b m} + 1$$

*kde  $H(A)$  je entropie zdroje symbolů z  $A$ ,  $b$  je stejné jako v  $H$  a  $m$  je velikost  $B$ .*

*$\bar{l}(C(A)) = \frac{H(A)}{\log_b m}$  právě když  $P(a_i) = m^{-l(a_i)}$  pro všechny  $a_i \in A$ .*



- redundance kódu:  $\bar{l}(C(A)) - \frac{H(A)}{\log_b m}$ , také v % z  $\frac{H(A)}{\log_b m}$ ,  $\bar{l}(C(A)) = \frac{H(A)}{\log_b m} \dots$  absolutně optimální kód

## Optimální kód

- změnou zdrojové abecedy na  $k$ -tice (nezávislých) symbolů z původní abecedy  $A$  (rozšíření zdrojové abecedy, source extension) se lze  $\bar{l}(C(A)) = \frac{H(A)}{\log_b m}$  libovolně přiblížit (až do  $k \rightarrow \infty$ ):

$$\begin{aligned}\frac{H(A^k)}{\log_b m} &\leq \bar{l}(C(A^k)) < \frac{H(A^k)}{\log_b m} + 1 \\ \frac{kH(A)}{\log_b m} &\leq k\bar{l}(C(A)) < \frac{kH(A)}{\log_b m} + 1 \\ \frac{H(A)}{\log_b m} &\leq \bar{l}(C(A)) < \frac{H(A)}{\log_b m} + \frac{1}{k}\end{aligned}$$



## Optimální kód

- změnou zdrojové abecedy na  $k$ -tice (nezávislých) symbolů z původní abecedy  $A$  (rozšíření zdrojové abecedy, source extension) se lze  $\bar{l}(C(A)) = \frac{H(A)}{\log_b m}$  libovolně přiblížit (až do  $k \rightarrow \infty$ ):

$$\begin{aligned}\frac{H(A^k)}{\log_b m} &\leq \bar{l}(C(A^k)) < \frac{H(A^k)}{\log_b m} + 1 \\ \frac{kH(A)}{\log_b m} &\leq k\bar{l}(C(A)) < \frac{kH(A)}{\log_b m} + 1 \\ \frac{H(A)}{\log_b m} &\leq \bar{l}(C(A)) < \frac{H(A)}{\log_b m} + \frac{1}{k}\end{aligned}$$

- abeceda  $A^k$  ale může mít velikost až  $n^k$  ( $n$  je velikost  $A$ )!

## Optimální kód

## Příklad

$$A = \{a_1, a_2, a_3\}$$

$$P(a_i) = 0.8, P(a_2) = 0.02, P(a_3) = 0.18$$

$$H(A) = -\sum_{i=1}^3 P(a_i) \log_2 P(a_i) \doteq 0.816 \text{ bitů/symbol}$$

$$C(A) = \{\langle a_1, \mathbf{0} \rangle, \langle a_2, \mathbf{II} \rangle, \langle a_3, \mathbf{IO} \rangle\}$$

$$\bar{l}(C(A)) = \sum_{i=1}^3 P(a_i) l(a_i) = 1.2 \text{ b/symbol}$$

$$\bar{l}(C(A)) - \frac{H(A)}{\log_2 2} \doteq 0.384 \text{ b/symbol} \doteq 47 \%$$

## Optimální kód

## Příklad

$$A = \{a_1, a_2, a_3\}$$

$$P(a_i) = 0.8, P(a_2) = 0.02, P(a_3) = 0.18$$

$$H(A) = -\sum_{i=1}^3 P(a_i) \log_2 P(a_i) \doteq 0.816 \text{ bitů/symbol}$$

$$C(A) = \{\langle a_1, \mathbf{0} \rangle, \langle a_2, \mathbf{II} \rangle, \langle a_3, \mathbf{IO} \rangle\}$$

$$\bar{l}(C(A)) = \sum_{i=1}^3 P(a_i) l(a_i) = 1.2 \text{ b/symbol}$$

$$\bar{l}(C(A)) - \frac{H(A)}{\log_2 2} \doteq 0.384 \text{ b/symbol} \doteq 47 \%$$

$$A^2 = \{a_1a_1, a_1a_2, a_1a_3, a_2a_1, a_2a_2, a_2a_3, a_3a_1, a_3a_2, a_3a_3\}$$

$$P(a_1a_1) = 0.64, P(a_1a_2) = P(a_2a_1) = 0.016, P(a_1a_3) = P(a_3a_1) = 0.144, P(a_2a_2) = 0.0004, P(a_2a_3) = P(a_3a_2) = 0.0036, P(a_3a_3) = 0.0324$$

$$C(A^2) = \{\langle a_1a_1, \mathbf{0} \rangle, \langle a_1a_2, \mathbf{IOIOI} \rangle, \langle a_1a_3, \mathbf{II} \rangle, \langle a_2a_1, \mathbf{IOI000} \rangle, \langle a_2a_2, \mathbf{IOI00IOI} \rangle, \langle a_2a_3, \mathbf{IOI00II} \rangle, \langle a_3a_1, \mathbf{IO0} \rangle, \langle a_3a_2, \mathbf{IOI00I00} \rangle, \langle a_3a_3, \mathbf{IOII} \rangle\}$$

$$\bar{l}(C(A)) = \frac{\bar{l}(C(A^2))}{2} = \frac{\sum_{i=1, j=1}^{3,3} P(a_i a_j) l(a_i a_j)}{2} \doteq \frac{1.723}{2} \doteq 0.862 \text{ b/symbol}$$

$$\bar{l}(C(A)) - \frac{H(A)}{\log_2 2} \doteq 0.046 \text{ b/symbol} \doteq 5.6 \%$$

## Optimální kód

### Věta

*Pro optimální prefixový kód ze zdrojové abecedy  $A$  do kódové abecedy  $B$  platí*

- 1** *Symbols  $z$   $A$  s větší pravděpodobností výskytu mají kratší kódová slova.*
- 2**  *$m' \in \{2, 3, \dots, m\}$ ,  $m' \equiv n \pmod{m-1}$ ) symbolů  $z$   $A$  s nejmenší pravděpodobností výskytu, kde  $n \geq 2$  je velikost  $A$  a  $m \geq 2$  je velikost  $B$ , má stejně (maximálně) dlouhá kódová slova a ta se liší pouze v jednom symbolu.* □

*Proč  $m'$  a ne  $m$ ? Odpověď u Huffmanova kódování (viz dále).*

# Základní techniky a kódování čísel

- = kódování posloupností stejných zdrojových symbolů (runs) kódy příznaku kódování opakování, délky posloupnosti a jednoho symbolu místo samotných symbolů
  - podle délky kódů příznaku a délky až pro posloupnosti delší než určitý počet  $k$  symbolů, např. 3
  - kód příznaku může být zaměnitelný s kódem symbolu  $\rightarrow$  kódování s kódem délky zmenšené o  $k$  za kódy určitého počtu  $k$  symbolů
  - aplikace: text, obraz (BMP)

## Diferenční kódování

- = kódování (malého) rozdílu symbolu/čísla od předchozího (nebo predikce z několika předchozích) kódy příznaku kódování rozdílu a rozdílu místo samotného symbolu/čísla, s výjimkou prvního

# Run-length encoding (RLE)



**Input:** číslo  $k$

$r \leftarrow 0$ ;

**while** načti ze vstupu symbol  $a$  **do**

**if**  $r = 0$  **then**

$x \leftarrow a$ ;

$r \leftarrow 1$ ;

**else**

**if**  $a = x$  **then**

$r \leftarrow r + 1$ ;

**else**

**if**  $r \leq k$  **then**

                zapiš na výstup  $r$  kódů symbolu  $x$ ;

**else**

                zapiš na výstup kódy příznaku, čísla  $r$  a symbolu  $x$  /  $k$  kódů symbolu  $x$  a kód čísla  $r - k$ ;

$x \leftarrow a$ ;

$r \leftarrow 1$ ;

PRIKLAD:  $k = 3$ , vstup *bbbbaaaarrrrbbaaaaara*, kod příznaku  $x$ , kod opakovaní číslo, kod symbolu symbol, obe varianty

= kódování často se opakujících symbolů malými čísly (speciálně posloupností stejných symbolů posloupností čísel 0)

■ lokálně adaptivní = adaptace podle lokálních četností výskytu symbolů

**Uses:** zdrojová abeceda  $A = \{a_1, \dots, a_n\}$ , (volitelně) pravděpodobnosti  $\{p_1, \dots, p_n\}$  výskytu  $a_i$

(volitelně) seřadit  $a_i$  a  $p_i$  tak, že  $p_i \geq p_j$  pro  $i < j$ ;

**while** načti ze vstupu symbol  $a \in A$  **do**

zapiš na výstup číslo  $i - 1$ , kde  $a_i = a$ ;

**if**  $i > 1$  **then**

$x \leftarrow a_i$ ;

$a_j \leftarrow a_{j-1}$  pro  $j = 2, 3, \dots, i$ ;

$a_1 \leftarrow x$ ;

**PRIKLAD:**  $A = \{a, b, r\}$ ,  $p(a) = \frac{10}{20}$ ,  $p(b) = \frac{6}{20}$ ,  $p(r) = \frac{4}{20}$ , vstup *bbbbaaaarrrbbaaaaara*, se setrizením i bez



- přirozených čísel – celá lze bijektivně zobrazit na přirozená (např.  $-2i$  pro  $i < 0$  a  $2i + 1$  pro  $i \geq 0$ )
- předpoklad nižší pravděpodobnosti výskytu u větších čísel
- binární kódy s proměnnou délkou (variable-length codes, fixed-to-variable codes) = proměnná délka kódových slov pro zdrojová slova pevné délky (symboly nebo jejich  $k$ -tice), nízká průměrná délka kódu vs. náročnější manipulace s kódem (v porovnání s blokovým kódem, s využitím bufferu)

## Unární kód

- kódování přirozených čísel
- = pro  $i \geq 0$ : zřetězení  $i$  **I** a **0** (nebo opačně), např. **IIIII0** pro 5
- prefixový, délka  $i + 1$ , optimální při  $P(i) = \frac{1}{2^i}$

## Další

- start-step-stop (obecné unární) kódy, start/stop kód, Levensteinův kód, Stoutovy kódy, Yamamotovy kódy, taboo kódy, Goldbachovy kódy, aditivní kódy aj.

- kódování přirozených čísel, P. Elias
- **Alpha** =  $\alpha(i)$  pro  $i \geq 0$ : unární kód  $i$ , s **I** na konci
- **Beta** =  $\beta(i)$  pro  $i \geq 0$ : reprezentace  $i$  ve dvojkové soustavě (= binární reprezentace) – neprefixový
- další – pro  $i \geq 1$ : zřetězení kódu  $l(\beta(i)) = \lfloor \log_2 i \rfloor + 1$  a  $\beta(i)$ , prefixové
- pro každé  $i \geq 1$ :  $i = 2^{l(\beta(i))-1} + k$ ,  $0 \leq k < 2^{l(\beta(i))-1}$

## Gamma

=  $\gamma(i)$  pro  $i \geq 1$ : zřetězení  $l(\beta(i)) - 1$  **0** a  $\beta(i)$  nebo  $\alpha(l(\beta(i)) - 1)$  a  $\beta(k)$ , např. **00I0I** pro 5

- délka  $2\lfloor \log_2 i \rfloor + 1$ , optimální při  $P(i) = \frac{1}{2i^2}$

## Delta

=  $\delta(i)$  pro  $i \geq 1$ : zřetězení  $l(\beta(l(\beta(i)))) - 1$  **0**,  $\beta(l(\beta(i)))$  a  $\beta(i)$  bez první **I** nebo  $\gamma(l(\beta(i)))$  a  $\beta(k)$ , např. **0II0I** pro 5

- délka  $2\lfloor \log_2 \log_2 2i \rfloor + \lfloor \log_2 i \rfloor + 1$ , optimální při  $P(i) = \frac{1}{2i(\log_2 2i)^2}$

## Omega (rekurzivní)

- =  $\omega(i)$  pro  $i = 1$ : **0**, a pro  $i \geq 2$ : zřetězení odzadu **0** a počínaje  $k := i$  pokud  $k \geq 2$  rekurzivně  $\beta(k)$ ,  $k := l(\beta(k)) - 1$ , např. **I0I0I0** pro 5
- dekódování:  $i := 1$  a opakovaně jestliže je další bit **I** tak s dalšími  $i$  bity tvoří kód  $\beta(i)$
- délka  $\sum_{j=1}^k (\lfloor \log_2 i \rfloor^j + 1) + 1$ ,  $\lfloor \log_2 i \rfloor^k = 1$

- kódování přirozených čísel, L. Pisano (Fibonacci)
- Fibonacciho reprezentace  $a_1 a_2 \dots$  přirozeného čísla  $i \geq 1$ :  $i = \sum_{j=1} a_j F_j$ ,  $a_j \in \{0, 1\}$ ,  $F_j$   $j$ -té Fibonacciho číslo ( $F_1 = 1, F_2 = 2, F_j = F_{j-1} + F_{j-2}$ ) – neobsahuje sousední 1
- = pro  $i \geq 1$ : zřetězení Fibonacciho reprezentace  $i$  (jako bitů) a **I**, např. **000II** pro 5 – končí **II**
- délka  $\leq \lfloor \log_{\phi} \sqrt{5}n \rfloor + 1$ ,  $\phi = \frac{1}{2}(1 + \sqrt{5}) \approx 1.618$  tzv. zlatý řez
- prefixové, robustnější než jiné kódy čísel
- další (zobecněné) založené na  $k$ -krokových (zobecněných) Fibonacciho číslech

- kódování přirozených čísel, S. W. Golomb

- parametr přirozené číslo  $j > 0$

= pro  $i \geq 0$  zřetězení dvou kódů:

- 1 unární kód  $q = \lfloor \frac{i}{j} \rfloor$  (= celé části  $\frac{i}{j}$ )

- 2  $\lceil \log_2 j \rceil$ -bitová binární reprezentace  $r = i - qj$  (= zbytek po celočíselném dělení  $\frac{i}{j}$ ) pro  $r = 0, 1, \dots, 2^{\lceil \log_2 j \rceil} - j - 1$  a  $\lceil \log_2 j \rceil$ -bitová binární reprezentace  $r + 2^{\lceil \log_2 j \rceil} - j$  pro  $r = 2^{\lceil \log_2 j \rceil} - j, \dots, j - 1$

## Příklad

$j = 5$

$\lfloor \log_2 5 \rfloor = 2$ -bitové binární reprezentace  $r = 0, 1, 2$  a  $\lceil \log_2 5 \rceil = 3$ -bitové binární reprezentace  $r + 3$  pro  $r = 3, 4$

$0 \mapsto \mathbf{000}$ ,  $1 \mapsto \mathbf{00I}$ ,  $2 \mapsto \mathbf{0IO}$ ,  $3 \mapsto \mathbf{0II0}$ ,  $4 \mapsto \mathbf{0III}$ ,  $5 \mapsto \mathbf{I000}$ ,  $6 \mapsto \mathbf{I00I}$ , ...

- délka pro malé  $j$  z malé rychle narůstá, pro velké  $j$  z delší narůstá pomalu
- prefixové, pro  $j = \lceil -\frac{1}{\log_2 p} \rceil$  (přesněji  $j = \lceil -\frac{\log_2(1+p)}{\log_2 p} \rceil$ ) optimální při  $P(i) = p^{i-1}(1-p)$  – geometrické rozdělení pravděpodobnosti, např. posloupnost (run z RLE)  $i-1$  výskytů symbolu s vysokou pravděpodobností výskytu  $p$  ukončená jedním výskytem jiného symbolu s nízkou pravděpodobností  $1-p$  (např. prohra a výhra) → (adaptivní) Golomb RLE
- použití např. v bezztrátové kompresi obrazu (JPEG-LS)

- ~ Golomb-Riceovy kódy, R. F. Rice (Rice machine)
- = Golombovy kódy pro  $j = 2^k$  pro nějaké (celé nezáporné)  $k$
- jednodušší kódování (a dekódování) pro  $i \geq 0$ : zřetězení unárního kódu pro zbývajících  $q = \lfloor \frac{i}{j} \rfloor$  bitů a  $k$  nejméně významných bitů binární reprezentace  $i$
- délka  $\lfloor \frac{i}{j} \rfloor + k + 1$ , optimální při  $P(i) = \frac{1}{2^{\frac{i}{j} + k + 1}}$
- použití např. v bezztrátové kompresi audia (MPEG-4 ALS, FLAC)